

✓ Topico: Arvores de decisao (Cálculo de Entropia e Ganho de Informação)

• Dados: {Sim, Sim, Não, Sim, Não, Não}

Calcula a Entropia inicial do Sistema e o Ganho de Informação ao dividir pelo atributo "Estudou".

- Total instâncias = 6. Positivas (P+) = 3, Negativas (p-) = 3.

• Passo 2: Entropia do Atributo 5

- // "Estudou = Sim" (3 instâncias): Todas são "Sim". Entropia = 0

Passo 3: Ganho de Informação (IG):
 $-16 = E_{\text{inicial}} - E_{\text{final}}$

- Interpretação: 0 atributo "Estudou"

Utilizando os dados de "Iron Jur" da elite

Dados de apoio (frequências dos slides):

- $P(\text{yes}) = 9/14$, $P(\text{no}) = 5/14$
- $P(\text{look} = \text{Overcast}) = 5/14$, $P(\text{look} = \text{Sunny}) = 4/14$, $P(\text{look} = \text{Rainy}) = 3/14$, $P(\text{look} = \text{Cloudy}) = 2/14$
- $P(\text{temp} = \text{Hot}) = 7/14$, $P(\text{temp} = \text{Mild}) = 6/14$, $P(\text{temp} = \text{Cool}) = 1/14$
- $P(\text{humidity} = \text{High}) = 8/14$, $P(\text{humidity} = \text{Normal}) = 6/14$
- $P(\text{wind} = \text{Weak}) = 9/14$, $P(\text{wind} = \text{Strong}) = 5/14$

- $P(\text{Overcast} | \text{Yes}) = 4/9$, $P(\text{Overcast} | \text{No}) = 0/5$
- $P(\text{Hot} | \text{Yes}) = 2/9$, $P(\text{Hot} | \text{No}) = 2/5$
- $P(\text{High} | \text{Yes}) = 3/9$, $P(\text{High} | \text{No}) = 2/5$
- $P(\text{Normal} | \text{Yes}) = 0/9$, $P(\text{Normal} | \text{No}) = 1/5$

$P(\text{Weak} | \text{Yes}) = 6/9$, $P(\text{Weak} | \text{No}) = 2/5$

Passo 1: Fórmula de Bayes: milhanea para yes:

- Substituted at: $9/14 \cdot 4/9 \cdot 2/9 \cdot 3/9 \cdot 6/9$

- Passo 2: Verificação para "111".
- Como 06

- Resultado final: A probabilidade total para "No" será 0.

Resposta Final: A classe x_1 tem 100% de probabilidade relativa (neste caso simplificado).

3. frequent itemset Mining (Algoritmo Apriori)

$D = \{1, 2, 3\}, \{1, 2, 4\}, \{2, 3, 4\}, \{1, 2, 3, 4\}$ e o suporte mínimo (mins)

processo do algoritmo Apriori para encontrar todas as associações frequentes ($L_1, L_2, \dots$).
Passo 1: Encontrar as associações frequentes de tamanho 1 (L_1).

Passo 1: Encontrar L (minsup=3):

Item 12: parece 3 vezes (Frequentes)
Item 34: aparece 4 vezes (frequentes)
Item 11: aparece 3 vezes (C)

$\Delta = \{1, 2, 3\}$ - parvul 3 vezus (Frequentes)
 Pass 2: $\Delta = \{1, 2, 3\}$

- {1, 2} Gerat Kandidaten Ez
- {1, 3} 3 vezes (Frequente) e filtra

- 1, 3} a parte 2 vezes (frequente)
- 2, 3} a parte 3 vezes (Não frequente)

as frequentes são L_1 e L_2 acima

4. Tópico: Avaliação de Modelos (Métricas de Erro)
Um modelo de regressão previu os seguintes valores ($\hat{y}$) para os valores reais (y):

- Real (y): [10, 15, 20]

- Previsto ($\hat{y}$): [12, 14, 18]

Pergunta: Calcule o MSE (Mean Squared Error) e o MAE (Mean Absolute Error) para este modelo.

- Cálculo do MAE:

- Erros absolutos: $|10-12|=2$; $|15-14|=1$; $|20-18|=2$

- $MAE = (2+1+2)/3 = 5/3 \approx 1.67$

- Cálculo do MSE:

- Erros Quadrados: $(10-12)^2=4$; $(15-14)^2=1$; $(20-18)^2=4$

- $MSE = (4+1+4)/3 = 9/3 = 3$.

5. Tópico: Ensemble (Bagging e Redução de ERRO)

Suponha que temos um conjunto de $M=5$ classificadores individuais. O erro médio de cada modelo agindo individualmente é $E_{AV} = 0.20$.

Se assumirmos que os erros dos modelos são totalmente não correlacionados, qual seria o erro esperado do Ensemble (E_{ENS}) segundo a fórmula de Bagging presente nos slides?

- Fórmula $E_{ENS} = \frac{1}{M} E_{AV}$ (válido apenas se os erros forem correlacionados).

- Substituição:

- $M=5$

- $E_{AV}=0.20$

- $E_{ENS} = 0.20/5 = 0.04$.

- Conclusão: O erro do ensemble é significativamente menor (4%) do que o erro individual (20%) devido à diversidade dos modelos.

6. Tópico: Algoritmos - Naive Bayes

No cálculo de probabilidades para o classificador Naive Bayes, por vezes deparamo-nos com frequências iguais a zero, o que anula todo o cálculo. Para evitar isso, usamos estimativas de probabilidades. Imagina que estás a prever se um aluno passa a uma cadeira (classe: passa ou ehumba). Na base de dados, a classe Passa tem um total de $n=8$ exemplos. Para o atributo "Estudou=pouco", significaste que o número de ocorrências dentro da classe Passa é $n_e=0$.

Assumindo um tamanho equivalente da amostra $m=3$ e uma probabilidade a priori uniforme para 3 possíveis valores do atributo ($p=1/3$), calcula a estimativa de probabilidade corrigida para $P(\text{Estudou=pouco} | \text{Passa})$.

1. Fórmula: A estimativa de probabilidades (m -estimate) é dado por $\frac{n_e + m \times p}{n + m}$.

2. Identificação das variáveis:

- $n_e=0$ (ocorrência de "pouco" na classe "Passa")

- $n=8$ (total de exemplos da classe "Passa")

- $m=3$ (tamanho equivalente da amostra)

- $p=1/3$ (probabilidade a priori)

3. Substituição

$$p = \frac{0 + 3 \times (1/3)}{8 + 3}$$

• Cálculo:

- Numerador: $0+1=1$

- Denominador: $8+3=11$

- Resultado final: $1/11 \approx 0.0909$ (ou 9.09%)

Estas a construir uma Árvore de Decisão e precisa de avaliar o atributo "Humidade" e fazer um split. O teu nó atual (nó pai) tem 12 instâncias no total: 9 da classe Sim e da classe Não.

Ao dividires pelo atributo "Humidade", obténs dois sub-nós:

- Humidade = Normal: 7 instâncias (6 Sim, 1 Não)
- Humidade = Alta: 5 instâncias (3 Sim, 2 Não)

Calcula o Information Gain deste split

1. Formulas:

• Entropia: $E = -\sum p_i \log p_i$

• Information gain: Inicial Entropy - E_A

2. Passo A - calcular a Entropia Inicial (Nó pai):

• Total = 12; $p(\text{Sim}) = 9/12 = 0.75$; $p(\text{Não}) = 3/12 = 0.25$

$$E_{\text{inicial}} = -(0.75 \times \log_2(0.75) + 0.25 \times \log_2(0.25))$$

$$E_{\text{inicial}} = 0.918$$

3. Passo B - calcular a Entropia dos sub-nós:

• No "Normal" (7 instâncias: 6 Sim, 1 Não):

• $p(\text{Sim}) = 6/7 \approx 0.857$; $p(\text{Não}) = 1/7 \approx 0.143$

$$E_{\text{normal}} = -(0.857 \times -0.222 + 0.143 \times -2.807) = 0.591$$

• No "Alta" (5 instâncias: 3 Sim, 2 Não):

• $p(\text{Sim}) = 3/5 = 0.6$; $p(\text{Não}) = 2/5 = 0.4$

$$E_{\text{alta}} = -(0.6 \times -0.737 + 0.4 \times -1.322) = 0.971$$

4. Passo C - calcular a Entropia Média Ponderada de Atributo (E_A):

$$E_{\text{Humidade}} = (7/12 \times E_{\text{normal}}) + (5/12 \times E_{\text{alta}})$$

$$E_{\text{Humidade}} = 0.749$$

5. Passo D - calcular o Information Gain

$$IG = E_{\text{inicial}} - E_{\text{Humidade}} = 0.918 - 0.749 = 0.169 \text{ information gain}$$

3. Tipo: Ensemble - AdaBoost

O algoritmo AdaBoost, as instâncias de treino são pesadas iterativamente. Uma determinada amostra foi mal classificada pelo modelo atual h_t . O peso anterior dessa amostra era $w_{old} = 0.05$. Sabendo que o peso calculado para este modelo na iteração atual é $\alpha_t = 1.2$, calcula o novo peso (antes da normalização) desta amostra.

1. Fórmula: A atualização de pesos é dada por $w_{new} = w_{old} \cdot \exp(\alpha_t \cdot \mathbb{I}(y_i \neq h_t(x_i)))$.

2. Identificações de variável:

$$w_{old} = 0.05$$

$$\alpha_t = 1.2$$

• Função indicadora $\mathbb{I}(y_i \neq h_t(x_i))$: como a amostra foi mal classificada, a condição é verdadeira, logo $\mathbb{I} = 1$.

3. Substituição

$$w_{new} = 0.05 \times \exp(1.2 \times 1)$$

4. Cálculo

$$w_{new} = 0.05 \times 3.320$$

• Resultado Final: 0.166. O peso aumentou, forçando o próximo classificador a dar mais importância a esta amostra.

1. Tipo: class Imbalance - SHOTE
 Para lidar com o desbalanceamento de classes, o algoritmo SHOTE gera amostras sintéticas através da interpolação geométrica entre uma instância da classe minoritária e os k -vizinhos mais próximos.

Selecione a instância minoritária $x_i = (10, 20)$ e um dos seus vizinhos aleatórios $x_{ci} = (15, 35)$. Se o algoritmo gerar o fator aleatório $\lambda = 0.6$, quais serão as coordenadas da nova amostra sintética x_{new} ?

1. Fórmula: A fórmula de interpolação geométrica é $x_{new} = x_i + \lambda \cdot (x_{ci} - x_i)$.

2. Identificação dos vetores:

- $x_i = (10, 20)$
- $x_{ci} = (15, 35)$
- $\lambda = 0.6$

3. Passo A - Calcular a diferença geométrica entre os vetores $(x_{ci} - x_i)$:

- $(15 - 10, 35 - 20) = (5, 15)$

4. Passo B - Multiplicar pelo fator aleatório λ :

- $0.6 \times (5, 15) = (3, 9)$

5. Passo C - Somar à instância original:

- $(10, 20) + (3, 9) = (13, 29)$

• Resultado final: A nova amostra sintética terá as coordenadas $(13, 29)$

0. Frequent Items - Algoritmo Eclat

O algoritmo Eclat utiliza uma representação vertical da Base de dados (TID-Lists). Bit vectors para calcular o support de itens de forma rápida.

Considere uma base de dados com 6 transações. O Bitvector para o item cerveja é 101101. O Bitvector para o item "Amendoim" é 111000. Simule a operação de interseção lógica (And) utilizada pelo ECLAT e indique qual é o suporte do itemset {cerveja, Amendoim}.

1. Certo: O suporte de um itemset com múltiplos itens é encontrado fazendo a interseção das duas TID-Lists. Com Bit vectors, isso equivale à operação lógica (And) bit-a-bit.

• Vetores:

- Cerveja: 101101
- Amendoim: 111000

3. Operação And:

- Posição: 1: 1 AND 1 = 1
- // 2: 0 AND 1 = 0
- // 3: 1 AND 1 = 1
- // 4: 1 AND 0 = 0
- // 5: 0 AND 0 = 0
- // 6: 1 AND 0 = 0

• vetor resultante = 101000

• cálculo do suporte: nr de bits no vetor resultante

• Resultado final: O suporte do itemset {cerveja, Amendoim} é 2.