



Universidade do Minho

Departamento de Informática

Mestrado [Integrado] em Engenharia Informática

Mestrado em Matemática e Computação

Nº _____ CURSO _____

NOME _____

Dados e Aprendizagem Automática

1º/4º Ano, 1º Semestre

Edição 2024/2025

Prova Escrita [A], 12 de dezembro, 2024

OBS: OS TERMOS EM INGLÊS CUJA TRADUÇÃO PODERIA GERAR CONFUSÃO FORAM MANTIDOS EM *ITÁLICO*.

GRUPO 1 (4 valores)

RESPONDA ÀS QUESTÕES DESTE GRUPO NO ESPAÇO RESERVADO PREENCHENDO OS ESPAÇOS VAZIOS COM AS EXPRESSÕES CORRETAS.

QUESTÃO 1 - Em *Machine Learning*, a _____ de dados recorre à discretização para reduzir a quantidade de valores de um atributo _____, dividindo-o em intervalos de igual _____.

QUESTÃO 2 - A _____ é uma técnica que _____ o conjunto de dados em _____ subconjuntos para treinar e testar o modelo várias vezes.

QUESTÃO 3 - A ideia do algoritmo _____ é utilizar a descida do _____ para otimizar os parâmetros de novos estimadores à medida que os _____ são adicionados no reforço.

QUESTÃO 4 - A aprendizagem com _____ envolve o aproveitamento das previsões de vários modelos _____ para criar um conjunto robusto e preciso de previsões, com cada modelo especializado numa _____ diferente do espaço definido pelos dados de entrada.

GRUPO 2 (4 valores)

RESPONDA ÀS QUESTÕES DESTE GRUPO EM FOLHA DE TESTE SEPARADA.

Atendendo ao conceito de *Feature Engineering*:

- defina-o no contexto de aprendizagem automática;
- enumere três (3) das suas técnicas;
- forneça um exemplo em que o seu uso melhorou significativamente o desempenho do modelo.

GRUPO 3 (4 valores)

RESPONDA ÀS QUESTÕES DESTE GRUPO EM FOLHA DE TESTE SEPARADA.

Comente as afirmações seguintes, assinalando a sua veracidade (V) ou falsidade (F), justificando a resposta. NÃO SÃO CONSIDERADAS respostas para as quais não exista justificação expressa.

QUESTÃO 1 - *Feature scaling* é uma técnica comumente aplicada na aprendizagem automática para normalizar a gama de variáveis independentes.

QUESTÃO 2 - A Regressão Logística é um modelo de *Machine Learning* utilizado para prever a probabilidade de uma classe ou evento, sendo amplamente aplicada em problemas de classificação binária.

QUESTÃO 3 - *Random Forest* são modelos de *Machine Learning* que imitam o funcionamento do cérebro no reconhecimento de padrões e fazer previsões a partir de dados

QUESTÃO 4 - O processo de *tuning* de hiperparâmetros é realizado apenas uma vez e não precisa ser ajustado durante o processo de treino do modelo.

GRUPO 4 (6 valores)

RESPONDA ÀS QUESTÕES DESTE GRUPO NO ESPAÇO RESERVADO.

Considere o *dataset "titanic.csv"*, usado diversas vezes no decurso do semestre, com o intuito de treinar um modelo de aprendizagem com capacidade de classificar a sobrevivência de passageiros do navio.

Considere, ainda, o excerto de código abaixo, onde se apresenta a preparação dos dados e a construção de um modelo de aprendizagem automática.

O excerto de código apresentado contém imprecisões. Identifique e corrija-as utilizando o espaço disponível ao lado do excerto (não deve copiar todo o excerto, mas apenas aquilo que corrigiu).

[1] df = pd.read_csv('titanic_dataset.csv')	[1] _____
[2] print(df.isna().any())	[2] _____
[3] corr_matrix = df.hist(numeric_only=True)	[3] _____
[4] x = df.drop(['Survived', 'Age', 'PassId', 'Name', 'Ticket', 'Cabin', 'Embarked', 'Sex'], axis=1)	[4] _____
[5] y = df['Cabin'].to_frame()	[5] _____
[6] x_train, x_test, y_train, y_test = train_test_split(y, x, test_size=0.25)	[6] _____
[7] model = LogisticRegression(criterion='gini')	[7] _____
[8] model.fit(x_train)	[8] _____
[9] print(model.intercept_)	[9] _____
[10] inferences = model.predict(y_test)	[10] _____
[11] print(confusion_matrix(x_test, inferences))	[11] _____
[12] print(accuracy_score(y_test, inferences))	[12] _____
[13] print(mean_absolute_error(x_train, y_train))	[13] _____
	[13] _____

GRUPO 5 (2 valores)

RESPONDA ÀS QUESTÕES DESTE GRUPO NO ESPAÇO RESERVADO.

Assinale a veracidade (v) ou falsidade (f) de cada uma das afirmações que se apresentam. Para cada questão, uma afirmação INCORRETAMENTE assinalada ANULA uma resposta assinalada corretamente.

QUESTÃO 1 - Árvores de Decisão:

- ☐ São técnicas de aprendizagem usadas em problemas de classificação;
- ☐ São métodos de validação de modelos contínuos;
- ☐ São técnicas de aprendizagem usadas em problemas de regressão;
- ☐ São métodos de validação de modelos discretos.

QUESTÃO 2 - *Support Vector Machines*:

- ☐ são modelos de aprendizagem supervisionada que podem ser usados para classificação;
- ☐ são modelos de aprendizagem supervisionada que podem ser usados para regressão;
- ☐ não podem lidar com dados desbalanceados, mesmo após o uso de técnicas como pesos ajustados ou *oversampling*;
- ☐ lidam com problemas não lineares ao transformar os dados num espaço de maior dimensionalidade usando o truque do *kernel*.