



Universidade do Minho
Departamento de Informática

Nº _____ CURSO _____

NOME _____

Dados e Aprendizagem Automática
1º Ano, 1º Semestre
Edição 2025/2026
[Prova Escrita, 17 de dezembro, 2025 - A]

OBS: OS TERMOS EM INGLÊS CUJA TRADUÇÃO PODERIA GERAR CONFUSÃO FORAM MANTIDOS EM ITÁLICO.

GRUPO 1 (4 valores) - RESPONDA ÀS QUESTÕES DESTE GRUPO NO ESPAÇO RESERVADO PREENCHENDO OS ESPAÇOS VAZIOS COM AS EXPRESSÕES CORRETAS.

QUESTÃO 1 – Durante o processo de preparação de dados, a técnica que consiste em transformar os valores numéricos num intervalo específico, geralmente entre 0 e 1, designa-se por _____. Por outro lado, a técnica que transforma os dados para que a média seja 0 e o desvio padrão 1 é designada por _____.

QUESTÃO 2 - No contexto do *Ensemble Learning*, o algoritmo _____ recorre à técnica de _____ para treinar múltiplas árvores de forma independente, enquanto algoritmos como o *XGBoost* utilizam a técnica de _____, na qual os modelos são construídos sequencialmente para corrigir os erros dos modelos anteriores.

QUESTÃO 3 - Nas Máquinas de Vetores de Suporte (SVM), quando os dados não são linearmente separáveis no espaço original, recorre-se a um _____ para projetar os dados num espaço de dimensão superior, de modo a encontrar um _____ que os separe.

QUESTÃO 4 – A avaliação de um modelo de _____ pode ser efetuada usando uma matriz de confusão, que possibilita o cálculo de várias métricas. A métrica que quantifica a proporção de verdadeiros positivos em relação ao total de casos classificados como positivos pelo modelo é denominada _____, enquanto a métrica que quantifica a proporção de verdadeiros positivos em relação ao total de casos realmente positivos é designada _____.

GRUPO 2 (4 valores) - RESPONDA ÀS QUESTÕES DESTE GRUPO EM FOLHA DE TESTE SEPARADA.

QUESTÃO 1 - Explique o conceito de *função valor* na aprendizagem por reforço.

QUESTÃO 2 - Distinga os algoritmos SARSA e Q-Learning focando-se nas suas políticas (*on/off policy*).

QUESTÃO 3 - Indique uma aplicação real em que o algoritmo Q-Learning é adequado e justifique.

GRUPO 3 (4 valores) - RESPONDA ÀS QUESTÕES DESTE GRUPO EM FOLHA DE TESTE SEPARADA.

Comente as afirmações seguintes, assinalando a sua veracidade (V) ou falsidade (F), justificando a resposta. NÃO SÃO CONSIDERADAS respostas para as quais não exista justificação expressa.

QUESTÃO 1 - O objetivo principal de um SVM na classificação de espécies de flores (*setosa* vs. *versicolor*) consiste em identificar o hiperplano que maximiza a margem (distância) entre os pontos de dados das duas classes mais próximos da fronteira.

QUESTÃO 2 - Considerando um conjunto de dados imobiliários com 100 colunas (*features*), das quais apenas 5 afetam efetivamente o preço, a regularização Lasso (L1) é a mais adequada, uma vez que permite a eliminação dos coeficientes das 95 variáveis irrelevantes, promovendo a seleção de características.

QUESTÃO 3 - O papel do gradiente na função de custo no treino de uma Regressão Logística é indicar a direção para onde o erro cresce mais depressa. O algoritmo procede à atualização dos pesos na direção oposta, com o propósito de minimizar o erro.

QUESTÃO 4 - Para prever a sobrevivência de um passageiro com base na idade e na tarifa paga, o modelo de classificação mais adequado é a Regressão Linear, visto a variável-alvo ser contínua.

GRUPO 4 (6 valores) - RESPONDA ÀS QUESTÕES DESTE GRUPO NO ESPAÇO RESERVADO.

Considere o *dataset* "titanic_dataset.csv", usado diversas ocasiões no decurso do semestre, com o intuito de treinar um modelo de aprendizagem com capacidade para prever os passageiros que sobreviveram, de acordo com algumas características. Adicionalmente, deve ser considerado o excerto de código apresentado abaixo, onde se demonstra a construção e avaliação de um modelo de aprendizagem automática. O excerto de código apresentado contém imprecisões. Identifique e corrija-as utilizando o espaço reservado para o efeito, ao lado do excerto (não deve copiar todo o excerto, mas apenas aquilo que corrigiu).

```

[1] df = pandas.read_csv("titanic_dataset.csv")
[2] X = df.remove (['Survived', 'PassengerID',
'Name', 'Sex', 'Age', 'Ticket', 'Cabin',
'Embarked'], axis=1)
[3] y = df['Survived']
[4] X_train, X_test, y_train, y_test =
sklearn.model_selection.train_test(X, y,
test_size=0.30, random_state=2022)
[5] dt_model = sklearn.tree.DecisionTree
(max_depth=2, random_state=2022)
[6] bg_model = sklearn.ensemble.BaggingClassifier
(estimator = strat_ss, bootstrap=True)
[7] strat_ss =
sklearn.model_selection.StratifiedShuffleSplit
(n_splits=10, test_size=20, random_state=2022)
[8] parameters = {'n_estimators':[10, 40, 60, 80,
100, 160]}
[9] grid_bg = sklearn.model_selection.GridSearchCV
(estimator=bg_model, param_grid=estimator,
cv=strat_ss)
[10] grid_bg.fit(X_train, y_train)
[11] best_bg_model.fit(X_train, y_train)
[12] best_bg_model = grid_bg.best_model_
[13] best_bg_score = best_bg_model.score (X_test,
y_test)
[14] best_bg_predictions =
best_bg_model.predict(y_test)
[15] print(sklearn.metrics.classification_report(
y_test, X_test))

```

- [1] _____
- [2] _____
- [3] _____
- [4] _____
- [5] _____
- [6] _____
- [7] _____
- [8] _____
- [9] _____
- [10] _____
- [11] _____
- [12] _____
- [13] _____
- [14] _____
- [15] _____

GRUPO 5 (2 valores) - RESPONDA ÀS QUESTÕES DESTE GRUPO NO ESPAÇO RESERVADO.

Assinale a veracidade (V) ou falsidade (F) de cada uma das afirmações apresentadas. Para cada questão, uma afirmação INCORRETAMENTE assinalada ANULA uma resposta assinalada corretamente.

QUESTÃO 1 – Em relação à aprendizagem não-supervisionada e, mais precisamente, ao *Clustering*:

- [] O algoritmo DBSCAN não exige conhecimento prévio sobre o número de *clusters* e possibilita igualmente a resolução de tarefas de detecção de anomalias;
- [] O algoritmo *K-Means* utiliza pontos reais do *dataset* (medóides) como representantes dos *clusters*, em vez de calcular médias das coordenadas (centróides);
- [] No método do cotovelo (*elbow method*), o número ideal de *clusters* corresponde sempre ao ponto onde a redução na variação é máxima;
- [] O algoritmo de *Hierarchical Clustering* requer obrigatoriamente que o número de *clusters* seja especificado como parâmetro antes da execução.

QUESTÃO 2 – Relativamente à exploração e preparação de dados:

- [] A técnica de One-Hot Encoding consiste na transformação de cada categoria de uma variável nominal num valor inteiro único, preservando a relação ordinal natural entre as categorias.
- [] No processo de binning, ao agrupar dados numéricos em intervalos, otimiza-se o desempenho do modelo , uma vez que se adiciona mais informação aos dados;
- [] A normalização é mais apropriada quando os dados seguem uma distribuição Gaussiana com média e desvio padrão bem comportados;
- [] A seleção de features tem como objetivo reduzir a dimensionalidade dos dados, removendo características redundantes ou irrelevantes, podendo reduzir o overfitting e melhorar a acurácia do modelo;