

Método de Descida Máxima, Método de Newton, Método de Newton Modificado, Métodos Quasi-Newton

Fernanda Costa

Departamento de Matemática
Universidade do Minho

Outline

- 1 Método de Descida Máxima
 - Taxa de convergência
- 2 Método de Newton
 - Taxa de Convergência
 - Limitações práticas do Método de Newton
 - Método de Newton Modificado
- 3 Métodos Quasi-Newton
 - O Método BFGS
 - Algoritmo do Método BFGS
 - Implementação

Método de Descida Máxima

No **Método de Descida Máxima** (ou **Método do Gradiente**), a direção de procura no ponto $w^{(k)}$ é a direção de *descida máxima*:

$$s^{(k)} = -\nabla F(w^{(k)}).$$

- A direção de descida máxima satisfaz a propriedade de descida:

$$s^{(k)\top} \nabla F(w^{(k)}) = -\nabla F(w^{(k)})^\top \nabla F(w^{(k)}) = -\|\nabla F(w^{(k)})\|^2 < 0.$$

- Entre todas as direções ao longo das quais F decresce, a direção oposta ao vetor gradiente é a de decrescimento mais acentuado. De facto, pela definição de produto interno entre dois vetores

$$s^{(k)\top} \nabla F(w^{(k)}) = \|s^{(k)}\| \|\nabla F(w^{(k)})\| \cos \theta$$

onde θ é o ângulo entre os vetores $s^{(k)}$ e $\nabla F(w^{(k)})$, e este termo tem o valor mínimo quando $\cos \theta = -1$, isto é, quando $\theta = \pi$, o que corresponde a $s^{(k)} = -\nabla F(w^{(k)})$.

O Método de Descida Máxima é definido pelo seguinte algoritmo iterativo.

Algoritmo: Método de Descida Máxima (MDM)

① **Entrada:** F , $w^{(0)}$, tolerância $\varepsilon > 0$

② Fazer $k = 0$

③ **Enquanto** $(\|\nabla F(w^{(k)})\|_\infty > \varepsilon)$ **fazer**

④ Calcular a direção de descida máxima $s^{(k)} = -\nabla F(w^{(k)})$

⑤ Calcular o comprimento do passo:

$$\eta_k = \text{Armijo}(F, \nabla F(w^{(k)}), w^{(k)}, s^{(k)}) \text{ com Bactracking}$$

⑥ Fazer $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}$

⑦ Fazer $k = k + 1$

⑧ **Fim enquanto**

⑨ **Saída:** $w^* \leftarrow w^{(k)}$, $F^* \leftarrow F(w^{(k)})$ (solução ótima e valor ótimo)

Taxa de convergência do Método de Descida Máxima

Podemos aprender muito sobre o **Método de Descida Máxima** considerando o caso ideal, no qual a função objetivo é quadrática e as procuras unidirecionais são exatas.

Considere-se

$$F(w) = \frac{1}{2} w^T Q w - b^T w,$$

onde $Q_{q \times q}$ é simétrica e definida positiva (SDP), $b \in \mathbb{R}^d$. O gradiente é dado por $\nabla F(w) = Qw - b$, e o minimizante w^* é a única solução do sistema linear: $\nabla F(w) = 0$, ou seja, $Qw = b$.

Seja $w^{(k)}$ a aproximação atual do MDM, com

$$F(w^{(k)}) = \frac{1}{2} w^{(k)T} Q w^{(k)} - b^T w^{(k)}.$$

Agora calculemos a próxima iteração do MDM.

Temos de calcular o η_k que minimiza $F(w^{(k)} - \eta \nabla F_k)$:

$$\phi(\eta) = F(w^{(k)} - \eta \nabla F_k) = \frac{1}{2} (w^{(k)} - \eta \nabla F_k)^T Q (w^{(k)} - \eta \nabla F_k) - b^T (w^{(k)} - \eta \nabla F_k)$$

onde ∇F_k representa $\nabla F(w^{(k)})$.

Expandindo o termo quadrático,

$$\begin{aligned}\phi(\eta) &= \frac{1}{2} w^{(k)T} Q w^{(k)} - \eta \nabla F_k^T Q w^{(k)} + \frac{1}{2} \eta^2 \nabla F_k^T Q \nabla F_k - b^T w^{(k)} + \eta b^T \nabla F_k \\ &= \underbrace{\frac{1}{2} w^{(k)T} Q w^{(k)} - b^T w^{(k)}}_{F(w^{(k)})} - \eta \nabla F_k^T Q w^{(k)} + \frac{1}{2} \eta^2 \nabla F_k^T Q \nabla F_k + \eta (Q w^{(k)} - \nabla F_k)^T \nabla F_k \\ &= F(w^{(k)}) - \eta \nabla F_k^T Q w^{(k)} + \frac{1}{2} \eta^2 \nabla F_k^T Q \nabla F_k + \eta (Q w^{(k)})^T \nabla F_k - \eta \nabla F_k^T \nabla F_k \\ &= F(w^{(k)}) + \frac{1}{2} \eta^2 \nabla F_k^T Q \nabla F_k - \eta \nabla F_k^T \nabla F_k.\end{aligned}$$

Agora derivando em relação a η :

$$\phi'(\eta) = \eta \nabla F_k^T Q \nabla F_k - \nabla F_k^T \nabla F_k$$

Pela condição de otimalidade $\phi'(\eta) = 0$, obtemos o comprimento de passo ótimo:

$$\eta_k = \frac{\nabla F_k^T \nabla F_k}{\nabla F_k^T Q \nabla F_k}.$$

Portanto, a próxima iteração $w^{(k+1)}$ do algoritmo MDM será:

$$w^{(k+1)} = w^{(k)} - \eta_k \nabla F_k = w^{(k)} - \frac{\nabla F_k^T \nabla F_k}{\nabla F_k^T Q \nabla F_k} \nabla F_k \quad (1)$$

com

$$\begin{aligned} F(w^{(k+1)}) &= F(w^{(k)} - \eta_k \nabla F_k) \\ &= F(w^{(k)}) + \frac{1}{2} \eta_k^2 \nabla F_k^T Q \nabla F_k - \eta_k \nabla F_k^T \nabla F_k \\ &= F(w^{(k)}) - \frac{1}{2} \frac{(\nabla F_k^T \nabla F_k)^2}{\nabla F_k^T Q \nabla F_k} \end{aligned}$$

Nota:

- Como $\nabla F_k = Qw^{(k)} - b$, a equação (1) produz uma expressão fechada para $w^{(k+1)}$ em termos de $w^{(k)}$.
- A Figura 1, mostra uma sucessão típica de iterados gerados pelo MDM aplicado a uma função quadrática bidimensional.
- Observe que os iterados apresentam um comportamento em ziguezague à medida que se aproximam da solução.
- Este ziguezague é uma forma não eficiente de aproximar-se do mínimo.




Figura 1: 7 iterações do MDM com procura exata, ao minimizar uma função quadrática convexa.

Teorema 1

Seja $F(w) = \frac{1}{2} w^T Q w - b^T w$, onde $Q_{d \times d}$ é SSDP. Seja $\{w^{(k)}\}$ a sucessão de iterados obtido pelo MDM com procura unidirecional exata, convergente para o minimizante global w^* de F . Então a sucessão $\{F(w^{(k)})\}$ converge linearmente para $F(w^*)$ com uma taxa de convergência

$$r = \left(\frac{\lambda_d/\lambda_1 - 1}{\lambda_d/\lambda_1 + 1} \right)^2$$

onde $0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_d$ são os valores próprios de Q .

Nota:

- Observe que, por definição de λ_d e λ_1 , λ_d/λ_1 é pelo menos 1. Se λ_d/λ_1 não for muito maior do 1 (pequeno) então a taxa de convergência r será muito menor que 1.
- Contudo, se λ_d/λ_1 for muito maior do 1 (grande), então a taxa de convergência r será ligeiramente menor que 1 e a velocidade de convergência será menor (i.e. será necessário um número maior de iterações até o MDM atingir a tolerância pretendida).

Síntese:

- Se F é limitada inferiormente, o **método de descida máxima**, com as condições de Wolfe (ou com procura exata, ou com a condição de Armijo com *backtracking*), é **globalmente convergente**.
- Contudo, apesar desta garantia teórica de convergência, o método pode revelar-se bastante ineficiente na prática.
- Vimos que, se $F(w)$ é uma função quadrática convexa, a sucessão $\{F(w^{(k)})\}$ obtida pelo método de descida máxima com procura exata *converge linearmente* para o mínimo global $F(w^*)$.

Método de Newton

Considere-se o problema de otimização sem restrições:

$$\underset{w \in \mathbb{R}^d}{\text{minimizar}} F(w)$$

onde $F : \mathbb{R}^d \rightarrow \mathbb{R}$ é duas vezes continuamente diferenciável.

Motivação:

- A ideia principal dos métodos de Newton baseia-se na observação, que, pelo menos localmente, uma função quadrática aproxima bem uma função não linear.
- Minimizar uma função quadrática é relativamente simples, pois a condição de primeira ordem é dada por um sistema de equações lineares.

Método de Newton: Para w numa vizinhança de $w^{(k)}$, o valor de $F(w)$ pode ser aproximado através da expansão quadrática da série de Taylor:

$$F(w) \approx m_k(w) \stackrel{\text{def}}{=} F(w^{(k)}) + (w - w^{(k)})^\top \nabla F(w^{(k)}) + \frac{1}{2} (w - w^{(k)})^\top \nabla^2 F(w^{(k)}) (w - w^{(k)}).$$

Direção de Newton

Se $\nabla^2 F(w^{(k)})$ é definida positiva, o minimizante global da função quadrática $m_k(w)$ é obtido resolvendo o sistema linear $\nabla m_k(w) = 0$, ou seja,

$$\nabla F(w^{(k)}) + \underbrace{\nabla^2 F(w^{(k)})(w - w^{(k)})}_{s^{(k)}} = 0.$$

A direção $s^{(k)}$, chamada de **direção de Newton** em $w^{(k)}$, é a solução deste sistema:

$$\nabla^2 F(w^{(k)}) s^{(k)} = -\nabla F(w^{(k)}) \quad (2)$$

ou seja,

$$s^{(k)} = -(\nabla^2 F(w^{(k)}))^{-1} \nabla F(w^{(k)}). \quad (3)$$

O método de Newton define então o novo ponto da forma:

$$w = w^{(k)} + s^{(k)}$$

(ou possivelmente realiza uma procura unidirecional - exata ou de Armijo - ao longo da direção $s^{(k)}$).

- **Nota:** O cálculo da direção $s^{(k)}$ é feito resolvendo o sistema linear (2) que tem um custo computacional menor do que o custo para inverter uma matriz, no caso de (3).

Algoritmo do Método de Newton (MN)

O **Método de Newton** é definido pelo seguinte algoritmo iterativo.

Algoritmo: Método de Newton (MN)

- 1 **Entrada:** F , $w^{(0)}$, tolerância $\varepsilon > 0$
 - 2 Fazer $k = 0$
 - 3 **Enquanto** $(\|\nabla F(w^{(k)})\|_\infty > \varepsilon)$ **fazer**
 - 4 Calcular a direção de Newton: $\nabla^2 F(w^{(k)}) s^{(k)} = -\nabla F(w^{(k)})$
 - 5 Calcular o comprimento do passo:
$$\eta_k = \text{Armijo}(F, \nabla F(w^{(k)}), w^{(k)}, s^{(k)}) \text{ com Bactracking}$$
 - 6 Fazer $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}$
 - 7 Fazer $k = k + 1$
 - 8 **Fim enquanto**
 - 9 **Saída:** $w^* \leftarrow w^{(k)}$, $F^* \leftarrow F(w^{(k)})$ (solução ótima e valor ótimo)
-

O teorema seguinte mostra que, se F é uma função quadrática convexa, então o método de Newton, quando iniciado em qualquer ponto $w^{(0)}$, atinge o minimizante global de F numa única iteração.

Teorema 2

Seja $F(w) = \frac{1}{2}w^T Qw + b^T w + c$ com $Q \in \mathbb{R}^d \times \mathbb{R}^d$ SDP (simétrica e definida positiva), $b \in \mathbb{R}^d$ e $c \in \mathbb{R}$. Então a sucessão de iterados obtida pelo método de Newton aplicado à minimização de F a partir de um qualquer ponto inicial $w^{(0)} \in \mathbb{R}^d$, atinge o minimizante global de F num único passo.

Demonstração:

Temos $\nabla F(w) = Qw + b$ e $\nabla^2 F(w) = Q$. O facto de Q ser SDP garante a convexidade estrita de F e, consequentemente, que a única solução do sistema linear $\nabla F(w) = 0 \Leftrightarrow Qw = -b$ é o minimizante global w^* de F .

Aplicando o MN, a direcção do MN é dada por:

$$\begin{aligned}s^{(0)} &= -(\nabla^2 F(w^{(0)}))^{-1} \nabla F(w^{(0)}) \\&= -Q^{-1}(Qw^{(0)} + b) \\&= -Q^{-1}(Qw^{(0)} - Qw^*) \\&= -w^{(0)} + w^*\end{aligned}$$

e o novo ponto é dado por $w^1 = w^{(0)} + s^{(0)} = w^{(0)} - w^{(0)} + w^* = w^*$.

Portanto, conclui-se que o MN converge para o minimizante w^* numa única iteração. $\square$

No caso mais geral em que a matriz hessiana, $\nabla^2 F(w)$, é SDP (F não necessariamente quadrática), o lema seguinte mostra que a direção de Newton $s^{(k)}$ é uma direção de descida!

Lema

Se $\nabla^2 F(w^{(k)})$ é definida positiva (DP), então a direção $s^{(k)}$ obtida da resolução do sistema $\nabla^2 F(w^{(k)}) s^{(k)} = -\nabla F(w^{(k)})$, é uma direção de descida.

Demonstração: Dado que $\nabla^2 F(w^{(k)})$ é definida positiva, a sua inversa existe e também é definida positiva. Logo, a direção de Newton é

$$s^{(k)} = -(\nabla^2 F(w^{(k)}))^{-1} \nabla F(w^{(k)}).$$

Temos então

$$\nabla F(w^{(k)})^T s^{(k)} = \nabla F(w^{(k)})^T (-(\nabla^2 F(w^{(k)}))^{-1} \nabla F(w^{(k)})) = -\nabla F(w^{(k)})^T \nabla^2 F(w^{(k)})^{-1} \nabla F(w^{(k)}) < 0,$$

pois $\nabla^2 F(w^{(k)})^{-1}$ é definida positiva. Portanto, $s^{(k)}$ é uma direção de descida para F no ponto $w^{(k)}$. $\square$

Taxa de convergência

O teorema seguinte mostra que a sucessão de iterados $\{w^{(k)}\}$ obtida pelo método de Newton (com $\eta_k = 1$), a partir de um ponto inicial $w^{(0)}$ suficientemente próximo do minimizante w^* de F , converge quadraticamente para w^* .

Teorema 3

Se w^* for um minimizante de $F : \mathbb{R}^d \rightarrow \mathbb{R}$, $F \in \mathcal{C}^3$, $w^{(k)}$ estiver suficientemente próximo de w^* e, além disso, existir uma constante h tal $\|(\nabla^2 F(w^{(k)}))^{-1}\| \leq h$, então o próximo iterado $w^{(k+1)}$ obtido pelo método de Newton satisfaz a desigualdade $\frac{\|w^{(k+1)} - w^*\|}{\|w^{(k)} - w^*\|^2} \leq r$ para uma certa constante r , isto é, a sucessão de iterados do método de Newton tem convergência quadrática.

Demonstração: Por aplicação do MN, $w^{(k+1)} = w^{(k)} - (\nabla^2 F(w^{(k)}))^{-1} \nabla F(w^{(k)})$. Então,

$$\begin{aligned} w^{(k+1)} - w^* &= w^{(k)} - w^* - (\nabla^2 F(w^{(k)}))^{-1} \nabla F(w^{(k)}) \\ &= (\nabla^2 F(w^{(k)}))^{-1} [\nabla^2 F(w^{(k)})(w^{(k)} - w^*) - \nabla F(w^{(k)})] \end{aligned}$$

e, atendendo a que $\nabla F(w^*) = 0$, podemos escrever

$$w^{(k+1)} - w^* = (\nabla^2 F(w^{(k)}))^{-1} [\nabla^2 F(w^{(k)})(w^{(k)} - w^*) + \nabla F(w^*) - \nabla F(w^{(k)})]. \quad (4)$$

Uma vez que $F \in \mathcal{C}^3$, a função F e as suas derivadas até à terceira ordem são contínuas numa vizinhança de $w^{(k)}$ e, por conseguinte, limitadas numa vizinhança de $w^{(k)}$. O Teorema de Taylor permite-nos então escrever que

$$\nabla F(w^*) - \nabla F(w^{(k)}) = \nabla^2 F(w^{(k)})(w^* - w^{(k)}) + \epsilon(w^*, w^{(k)}),$$

onde $\|\epsilon(w^*, w^{(k)})\| \leq r_1 \|w^* - w^{(k)}\|^2$. Por conseguinte,

$$\begin{aligned} & \|\nabla^2 F(w^{(k)})(w^{(k)} - w^*) + \nabla F(w^*) - \nabla F(w^{(k)})\| = \\ & = \|\nabla^2 F(w^{(k)})(w^{(k)} - w^*) - \nabla^2 F(w^{(k)})(w^{(k)} - w^*) + \epsilon(w^*, w^{(k)})\| \\ & = \|\epsilon(w^*, w^{(k)})\| \\ & \leq r_1 \|w^{(k)} - w^*\|^2 \end{aligned}$$

e resulta de (4) que

$$\|w^{k+1} - w^*\| \leq r_1 \|(\nabla^2 F(w^{(k)})^{-1})\| \|w^{(k)} - w^*\|^2.$$

Como por hipótese $\|(\nabla^2 F(w^{(k)})^{-1})\| \leq h$, concluímos que

$$\|w^{k+1} - w^*\| \leq r \|w^{(k)} - w^*\|^2$$

para $r = r_1 h$. $\square$

Limitações práticas do Método de Newton I

- O passo completo de Newton pode não reduzir F .

- Mesmo que $\nabla^2 F(w^{(k)})$ seja definida positiva ($s^{(k)}$ é uma direção de descida), o passo completo pode não reduzir o valor da função:

$$F(w^{(k)} + s^{(k)}) > F(w^{(k)}).$$

- **Recomendação:** determinar o comprimento do passo η_k fazendo uma *procura unidirecional* - exata ou condição Armijo com Backtracking.

Limitações práticas do Método de Newton II

- O método de Newton requer a resolução de um **sistema linear** em cada iteração.
 - Para problemas com milhões de variáveis, este cálculo pode tornar-se computacionalmente muito dispendioso.
 - **Recomendação:** utilizar métodos iterativos para resolver o sistema linear, como por exemplo o método dos *gradientes conjugados*.
- O método de Newton requer o cálculo das **derivadas de primeira e segunda ordem**.
 - As derivadas podem ser aproximadas por **diferenças finitas**, mas este procedimento é computacionalmente dispendioso e sujeito a erros numéricos.
 - As derivadas também podem ser obtidas usando **diferenciação automática**: podemos calcular o gradiente com um custo computacional proporcional à avaliação da função, tornando os cálculos de gradiente viáveis. No entanto, para problemas com milhões de variáveis, o cálculo da **Hessiana** continua a ser muito dispendioso!
- Estas limitações motivaram o desenvolvimento dos Métodos Quasi-Newton, apresentados na secção seguinte.

Limitações práticas do Método de Newton III

- A matriz Hessiana $\nabla^2 F(w^{(k)})$ pode não ser definida positiva.
 - Se $\nabla^2 F(w^{(k)})$ é definida negativa, $s^{(k)}$ não é uma direção de descida e não é possível garantir a existência de η_k que verifique

$$F(w^{(k)} + \eta_k s^{(k)}) < F(w^{(k)}).$$

- Se $\nabla^2 F(w^{(k)})$ é indefinida, $s^{(k)}$ pode não ser uma direção de descida e pode até tornar-se ortogonal à direção de descida máxima, $-\nabla F(w^{(k)})$. Neste caso, também não é possível garantir a existência de η_k que reduza o valor de F .
- Se $\nabla^2 F(w^{(k)})$ é singular, a direção $s^{(k)}$ nem sequer está definida.
- **Recomendação:** modificar $\nabla^2 F(w^{(k)})$ de modo a torná-la definida positiva, garantindo assim que $s^{(k)}$ seja uma direção de descida.

Método de Newton Modificado

- A matriz Hessiana pode ser modificada através de uma **fatorização modificada de Cholesky**:

$$\nabla^2 F(w^{(k)}) + E_k = L_k L_k^\top$$

onde E_k é uma matriz diagonal e L_k é uma matriz triangular inferior com elementos da diagonal positivos. Assim, $\nabla^2 F(w^{(k)}) + E_k$ é definida positiva.

- Se $\nabla^2 F(w^{(k)})$ já for definida positiva, então $E_k = 0$ (não é necessária qualquer modificação). Caso contrário, E_k introduz uma pequena correção na diagonal para garantir a positividade.
- Em MATLAB, a função `chol(A, 'lower')`, permite calcular a factorização $L_k L_k^\top$ de uma matriz simétrica definida positiva A , com L_k uma matriz triangular inferior com elementos da diagonal positivos.
- Na prática, a modificação da Hessiana é incorporada durante a resolução do sistema linear, utilizando a factorização.

Algoritmo do Método de Newton Modificado

O **Método de Newton Modificado** é definido pelo seguinte algoritmo iterativo.

Algoritmo: Método de Newton Modificado

- 1 **Entrada:** F , $w^{(0)}$, tolerância $\varepsilon > 0$
 - 2 Fazer $k = 0$
 - 3 **Enquanto** $(\|\nabla F(w^{(k)})\|_\infty > \varepsilon)$ **fazer**
 - 4 Factorizar a matriz: $\nabla^2 F(w^{(k)}) + E_k = L_k L_k^\top$
 - 5 Calcular a direção de Newton: $(L_k L_k^\top) s^{(k)} = -\nabla F(w^{(k)})$
 - 6 Calcular o comprimento do passo:
$$\eta_k = \text{Armijo}(F, \nabla F(w^{(k)}), w^{(k)}, s^{(k)}) \text{ com Bactracking}$$
 - 7 Fazer $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}$
 - 8 Fazer $k = k + 1$
 - 9 **Fim enquanto**
 - 10 **Saída:** $w^* \leftarrow w^{(k)}$, $F^* \leftarrow F(w^{(k)})$ (solução ótima e valor ótimo)
-

- Os **Métodos Quasi-Newton**, como o método de descida máxima, apenas requerem **gradiente** da função objetivo em cada iteração.
- Medindo a **variação nos gradientes**, constroem um modelo da função objetivo que é preciso o suficiente para obter **convergência superlinear**.
- A melhoria relativamente ao método de descida máxima é drástica, sobretudo em problemas difíceis.
- Além disso, como as **segundas derivadas** não são necessárias, os métodos Quasi-Newton são, por vezes, mais eficientes do que o método de Newton.

- O desenvolvimento de técnicas de **diferenciação automática** tornou possível utilizar o método de Newton sem exigir que o utilizador forneça as segundas derivadas.
- No entanto, estas ferramentas podem não ser aplicáveis em muitas situações, e pode ser muito mais dispendioso trabalhar com as segundas derivadas em software de diferenciação automática do que com o cálculo do gradiente.
- Por estas razões, os métodos Quasi-Newton continuam a ser atrativos.
- Atualmente, bibliotecas de software de otimização incluem vários **algoritmos Quasi-Newton** para problemas de otimização sem restrições, com restrições e de grande dimensão. Nesta secção, apresentamos os métodos Quasi-Newton para problemas de pequena e média dimensão. No próximo capítulo apresentamos a sua extensão para os problemas de grande dimensão.

Para entender como foram desenvolvidos os **Métodos Quasi-Newton**, considere-se o seguinte modelo quadrático para a função objetivo F no ponto $w^{(k)}$:

$$m_k(w) \stackrel{\text{def}}{=} F(w^{(k)}) + (w - w^{(k)})^\top \nabla F(w^{(k)}) + \frac{1}{2}(w - w^{(k)})^\top B_k (w - w^{(k)}).$$

onde B_k é uma matriz $d \times d$ simétrica definida positiva que deve ser **atualizada a cada iteração**. O minimizante desta função quadrática, é dado por $\nabla m_k(w) = 0$, ou seja,

$$\nabla F(w^{(k)}) + \underbrace{B_k (w - w^{(k)})}_{s^{(k)}} = 0.$$

A direção $s^{(k)}$, chamada de direção quasi-Newton em $w^{(k)}$, é a solução deste sistema:

$$B_k s^{(k)} = -\nabla F(w^{(k)})$$

ou seja,

$$\boxed{s^{(k)} = -B_k^{-1} \nabla F(w^{(k)})}. \quad (5)$$

E o novo iterado é

$$w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}, \quad (6)$$

onde η_k é escolhido de forma a satisfazer as condições Wolfe.

Nota: este processo é semelhante ao MN, a principal diferença é que aproximação B_k é usada em vez da verdadeira Hessiana.

Tendo-se o novo ponto $w^{(k+1)}$, o novo modelo quadrático para F no ponto $w^{(k+1)}$ é

$$m_{k+1}(w) \stackrel{\text{def}}{=} F(w^{(k+1)}) + (w - w^{(k+1)})^\top \nabla F(w^{(k+1)}) + \frac{1}{2} (w - w^{(k+1)})^\top B_{k+1} (w - w^{(k+1)}).$$

Como determinar B_{k+1} ?

Que condições deve satisfazer B_{k+1} com base na informação obtida no último passo?

Uma condição natural é que o modelo quadrático m_{k+1} tenha o mesmo gradiente que F nos dois últimos iterados $w^{(k)}$ e $w^{(k+1)}$, ou seja,

$$\nabla m_{k+1}(w^{(k)}) = \nabla F(w^{(k)})$$

$$\nabla m_{k+1}(w^{(k+1)}) = \nabla F(w^{(k+1)})$$

Como $\nabla m_{k+1}(w) = \nabla F(w^{(k+1)}) + B_{k+1}(w - w^{(k+1)})$ temos:

- a segunda condição encontra-se automaticamente verificada pois

$$\nabla m_{k+1}(w^{(k+1)}) = \nabla F(w^{(k+1)}) + B_{k+1}(w^{(k+1)} - w^{(k+1)}) = \nabla F(w^{(k+1)})$$

- a primeira condição pode ser escrita matematicamente como

$$\nabla m_{k+1}(w^{(k)}) = \nabla m_{k+1}(w^{(k+1)} - \eta_k s^{(k)}) = \nabla F(w^{(k+1)}) - \eta_k B_{k+1} s^{(k)} = \nabla F(w^{(k)}).$$

Rearranjando, obtém-se

$$B_{k+1} \eta_k s^{(k)} = \nabla F(w^{(k+1)}) - \nabla F(w^{(k)}). \quad (7)$$

Para simplificar a notação definem-se os vetores

$$\boxed{p^{(k)} = w^{(k+1)} - w^{(k)}} \quad \boxed{y^{(k)} = \nabla F(w^{(k+1)}) - \nabla F(w^{(k)})}$$

de modo que (7) torna-se

$$\boxed{B_{k+1} p^{(k)} = y^{(k)}}. \quad (8)$$

Esta fórmula é conhecida como a **equação secante**.

Assim, dado $p^{(k)}$ (deslocamento) e $y^{(k)}$ (variação do gradiente), a equação secante requer que a matriz simétrica definida positiva B_{k+1} transforme $p^{(k)}$ em $y^{(k)}$. Mas isto só é possível se $p^{(k)}$ e $y^{(k)}$ satisfizerem a **condição de curvatura**

$$(p^{(k)})^\top y^{(k)} > 0 \quad (9)$$

como se pode facilmente verificar multiplicando (8) por $(p^{(k)})^\top$.

- Quando a condição de curvatura (9) é satisfeita, a equação secante (7) sempre tem uma solução B_{k+1} . Na verdade, admite um número infinito de soluções!
- Dado que a matriz simétrica definida positiva B_{k+1} (de ordem d) tem $d(d+1)/2$ elementos distintos, a equação secante por si só não é suficiente para determinar B_{k+1} de modo único.
- Assim, para definir um Método Quasi-Newton específico, é necessário impor condições adicionais, sendo as fórmulas de atualização dadas por:

$$B_{k+1} = B_k + C_k, \quad k = 0, 1, 2, \dots,$$

onde C_k representa uma atualização para a matriz atual B_k .

- Existem várias escolhas possíveis para as matrizes C_k . Podem ser escolhidas por forma a serem:
 - ▶ **matrizes de característica um**
($C = auu^T$, onde a é um escalar e u é vetor).
 - ▶ **matrizes de característica dois**
($C = auu^T + bvv^T$, onde a e b são escalares, e u e v são vetores).
- Muitas fórmulas de atualização foram propostas ao longo dos anos. Aqui, vamos apenas apresentar a mais popular:
 - ▶ **fórmula BFGS** (desenvolvida por **B**royden - **F**letcher - **G**oldafard - **S**hanno).

O Método BFGS

Seja B_0 uma matriz simétrica definida positiva.

A fórmula de atualização BFGS é uma fórmula de atualização de característica-dois

$$B_{k+1} = B_k + auu^\top + bv v^\top$$

com $u = y^{(k)}$ e $v = B_k p^{(k)}$, e com os escalares a e b determinados de modo a que a atualização, B_{k+1} , satisfaça a equação secante (8). Assim, temos

$$y^{(k)} = B_{k+1} p^{(k)} = B_k p^{(k)} + a y^{(k)} \underbrace{y^{(k)\top} p^{(k)}} + b B_k p^{(k)} \underbrace{p^{(k)\top} B_k p^{(k)}}$$

e a condição (8) é verificada se

$$a = \frac{1}{y^{(k)\top} p^{(k)}} \quad \text{e} \quad b = -\frac{1}{p^{(k)\top} B_k p^{(k)}}$$

Portanto, a fórmula de atualização BFGS é dada por:

$$B_{k+1} = B_k + \frac{y^{(k)} y^{(k)\top}}{y^{(k)\top} p^{(k)}} - \frac{B_k p^{(k)} p^{(k)\top} B_k}{p^{(k)\top} B_k p^{(k)}}. \quad (10)$$

Nota: Facilmente se verifica que $B_{k+1} p^{(k)} = y^{(k)}$.

A inversa de B_k , que denotamos por

$$H_k = B_k^{-1}$$

é útil na implementação do método, pois permite calcular a direção de procura (5) através de uma simples multiplicação matriz-vetor

$$s^{(k)} = -H_k \nabla F(w^{(k)}). \quad (11)$$

Utilizando a fórmula de Sherman–Morrison–Woodbury, podemos obter a seguinte expressão para a atualização da aproximação da inversa da Hessiana H_k que corresponde à atualização BFGS de B_k em (10):

$$H_{k+1} = H_k - \left(\frac{H_k y^{(k)} p^{(k)\top} + p^{(k)} y^{(k)\top} H_k}{y^{(k)\top} p^{(k)}} \right) + \left(1 + \frac{y^{(k)\top} H_k y^{(k)}}{y^{(k)\top} p^{(k)}} \right) \frac{p^{(k)} p^{(k)\top}}{y^{(k)\top} p^{(k)}} \quad (12)$$

Nota: Facilmente se verifica que $H_{k+1} y^{(k)} = p^{(k)}$.

O lema seguinte mostra que a atualização BFGS é definida positiva se $y^{(k)\top} p^{(k)} > 0$.

Lema

Se $y^{(k)\top} p^{(k)} > 0$, então a atualização BFGS preserva a matriz definida positiva.

- No entanto, a condição $y^{(k)\top} p^{(k)} > 0$ nem sempre é satisfeita no caso de funções não convexas.
- Para garantir que $y^{(k)\top} p^{(k)} > 0$, basta impor as condições de Wolfe no procedimento de procura unidirecional. De facto, pela condição de Wolfe tem-se

$$\nabla F(w^{(k+1)})^\top s^{(k)} \geq c_2 \nabla F(w^{(k)})^\top s^{(k)},$$

e, portanto,

$$y^{(k)\top} p^{(k)} = (\nabla F(w^{(k+1)}) - \nabla F(w^{(k)}))^\top p^{(k)} \geq (c_2 - 1) \eta_k \nabla F(w^{(k)})^\top s^{(k)}.$$

Como $c_2 < 1$ e $s^{(k)}$ é uma direção de descida, o termo do lado direito é positivo. Assim, a condição de curvatura $y^{(k)\top} p^{(k)} > 0$ é satisfeita.

Algoritmo do Método BFGS

O **Método BFGS** é definido pelo seguinte algoritmo iterativo.

Algoritmo: Método BFGS

- 1 **Entrada:** F , $w^{(0)}$, H_0 , tolerância $\varepsilon > 0$
- 2 Fazer $k = 0$
- 3 **Enquanto** $(\|\nabla F(w^{(k)})\|_\infty > \varepsilon)$ **fazer**
- 4 Calcular a direção de procura: $s^{(k)} = -H_k \nabla F(w^{(k)})$
- 5 Calcular o comprimento do passo η_k
$$\eta_k = \text{Wolfe}(F, \nabla F(w^{(k)}), w^{(k)}, s^{(k)}) \text{ com Bactracking}$$
- 6 Fazer $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}$
- 7 Definir $p^{(k)} = w^{(k+1)} - w^{(k)}$
- 8 Definir $y^{(k)} = \nabla F(w^{(k+1)}) - \nabla F(w^{(k)})$
- 9 Calcular H_{k+1} usando a fórmula (12)
- 10 Fazer $k = k + 1$
- 11 **Fim enquanto**
- 12 **Saída:** $w^* \leftarrow w^{(k)}$, $F^* \leftarrow F(w^{(k)})$ (solução ótima e valor ótimo)

Algoritmo: Procura unidirecional com condições de Wolfe (backtracking)

- 1 **Entrada:** $\eta_0 > 0$, $\rho \in (0, 1)$, $c_1, c_2 \in (0, 1)$, F , $\nabla F(w^{(k)})$, $w^{(k)}$, $s^{(k)}$
 - 2 Fazer $\eta = \eta_0$
 - 3 **Enquanto** (verdadeiro) **fazer**
 - 4 (Condição de Armijo)
 - 5 **Enquanto** $F(w^{(k)} + \eta s^{(k)}) > F(w^{(k)}) + c_1 \eta \nabla F(w^{(k)})^T s^{(k)}$ **fazer**
 - 6 Fazer $\eta = \rho \eta$
 - 7 **Fim enquanto**
 - 8 (Condição de curvatura)
 - 9 Se $\nabla F(w^{(k)} + \eta s^{(k)})^T s^{(k)} < c_2 \nabla F(w^{(k)})^T s^{(k)}$ **então**
 - 10 Fazer $\eta = \rho \eta$
 - 11 Senão **Sair:** $\eta_k = \eta$
 - 12 **Fim se**
 - 13 **Fim enquanto**
 - 14 **Saída:** η_k
-

Implementação I

- A procura unidirecional, que deve satisfazer as condições de Wolfe, deve usar sempre $\eta_0 = 1$, pois este passo poderá eventualmente ser aceite, produzindo assim *convergência superlinear* do algoritmo.
- No procedimento de procura unidirecional, os valores $c_1 = 10^{-4}$ e $c_2 = 0.9$ são muito usados.
- A matriz inicial H_0 frequentemente é definida como algum múltiplo βI da matriz identidade, mas não existe nenhuma estratégia para escolher o valor de β .
- Uma heurística que frequentemente se mostra bastante eficaz é escalar a matriz inicial H_0 após o primeiro passo ter sido calculado, mas antes de realizar a primeira atualização BFGS. Substituímos o valor provisório $H_0 = I$ por

$$H_0 \leftarrow \frac{y_k^\top s_k}{y_k^\top y_k} I,$$

antes de aplicar a fórmula de atualização (12) para obter H_1 .

Implementação II

- O desempenho do método BFGS pode degradar-se se a procura unidirecional não for baseada nas condições de Wolfe.
- Por exemplo, alguns softwares implementam uma **procura unidirecional de Armijo com backtracking**: o passo unitário $\eta_k = 1$ é tentado primeiro e é sucessivamente reduzido até que a condição de Armijo seja satisfeita.

Porém, **não há garantia de que a condição de curvatura**, $y_k^\top s_k > 0$, seja satisfeita pelo η_k obtido, pois pode ser necessário um valor de $\eta_k > 1$ para satisfazer esta condição.

- Para contornar esta limitação, algumas implementações simplesmente **não aplicam a atualização BFGS** (estratégia de *skipping*), definindo

$$H_{k+1} = H_k$$

se $y^{(k)\top} p^{(k)}$ é *negativo* ou *próximo de zero*. Mas esta estratégia não é muito aconselhável.

- Existe uma atualização **damped BFGS**, que é uma estratégia mais eficaz para lidar com os casos em que a condição de curvatura não é satisfeita.

