

Métodos de Penalidade:

Método de Penalidade Quadrática e Métodos de Penalidade Exata

Fernanda Costa

Departamento de Matemática
Universidade do Minho

- 1 Métodos de Penalidade
- 2 Método de Penalidade Quadrática
 - Algoritmo do Método de Penalidade Quadrática
 - Observações sobre o Algoritmo
 - Convergência
- 3 Métodos de Penalidade Exata Não Suaves
 - Propriedades da Função de Penalidade Exata ℓ_1
 - Algoritmo do Método de Penalidade ℓ_1
 - Observações sobre o Algoritmo
 - Classe Geral de Métodos de Penalidade Exata Não Suaves

Métodos de Penalidade

Considere a seguinte formulação geral do problema de otimização com restrições:

$$\begin{array}{ll} \underset{w \in \mathbb{R}^d}{\text{minimizar}} & F(w) \\ \text{sujeito a} & c_n(w) = 0, \quad n \in \mathcal{E} \\ & c_n(w) \geq 0, \quad n \in \mathcal{I} \end{array} \quad (\text{P}_{CR})$$

- $w = (w_1, w_2, \dots, w_d)^T$ é o vetor das variáveis de decisão
- $F : \mathbb{R}^d \rightarrow \mathbb{R}$ é a função objetivo (medida de desempenho)
(loss or cost function in ML)
- $c_n : \mathbb{R}^d \rightarrow \mathbb{R}$ com $n \in \mathcal{E}$, são as funções de restrição de igualdade
- $c_n : \mathbb{R}^d \rightarrow \mathbb{R}$ com $n \in \mathcal{I}$, são as funções de restrição de desigualdade
- **nota:** em (P_{CR}) as funções de restrição $c_n(w)$, para $n \in \mathcal{E}$ e $n \in \mathcal{I}$, podem ser agrupadas nas funções vetoriais $c_{\mathcal{E}} : \mathbb{R}^d \rightarrow \mathbb{R}^{|\mathcal{E}|}$ e $c_{\mathcal{I}} : \mathbb{R}^d \rightarrow \mathbb{R}^{|\mathcal{I}|}$:

$$\begin{array}{l} c_{\mathcal{E}}(w) = 0 \\ c_{\mathcal{I}}(w) \geq 0 \end{array}$$

- Uma classe importante de métodos para resolver problemas de otimização com restrições é a dos **Métodos de Penalidade**.
- A ideia dos métodos de penalidade consiste em substituir o problema com restrições (P_{CR}) por uma sucessão de problemas sem restrições, adicionando à função objetivo um termo de penalidade para cada restrição. Esse termo penaliza - isto é, aumenta o valor da função objetivo - sempre que a restrição é violada.
- Vamos apresentar duas abordagens:
 - ▶ **Método de Penalidade Quadrática**
 - ▶ **Métodos de Penalidade Exata**

Método de Penalidade Quadrática

Motivação:

- O problema com restrições (P_{CR}) é substituído por uma **função de penalidade**, definida por:
 - a **função objetivo do problema original**, à qual é adicionado
 - um **termo de penalidade** por restrição, que é positivo quando o ponto w **viola a restrição** e nulo caso contrário.
- A maioria dos métodos de penalidade define uma sequência de funções de penalidade, em que os **termos de penalidade** são multiplicados por um coeficiente positivo μ , designado por **parâmetro de penalidade**.
- Ao aumentar o valor de μ , penalizam-se as violações das restrições de forma mais severa, forçando o minimizante da função de penalidade a aproximar-se da região admissível do problema com restrições original.
- A função de penalidade mais simples deste tipo é a **função de penalidade quadrática**.

Método de Penalidade Quadrática

- Para o problema com restrições (P_{CR}), define a **função de penalidade quadrática** $Q(w; \mu)$, com $\mu > 0$, dada por:

$$Q(w; \mu) = \underbrace{F(w)}_{\text{função objetivo}} + \underbrace{\frac{\mu}{2} \sum_{n \in \mathcal{E}} (c_n(w))^2 + \frac{\mu}{2} \sum_{n \in \mathcal{I}} (\max(0, -c_n(w)))^2}_{\text{um termo de penalidade por restrição, definido pelo quadrado da violação da restrição}}$$

- A seguir, define uma sucessão de problemas sem restrições da forma:

$$\underset{w \in \mathbb{R}^d}{\text{minimizar}} \quad Q(w, \mu_k)$$

para uma sucessão crescente dos parâmetros de penalidade μ , com $\mu_k \rightarrow \infty$ quando $k \rightarrow \infty$.

- Ao fazer o valor de $\mu_k \rightarrow \infty$, penaliza as violações das restrições de forma mais severa, forçando o minimizante de $Q(w; \mu_k)$ a ficar cada vez mais próximo da região admissível do problema original (P_{CR}).

O Método de Penalidade Quadrática é definido pelo seguinte algoritmo.

Algoritmo 8.1: Método de Penalidade Quadrática

- 1 **Entrada:** F e c_n para $n \in \mathcal{E} \cup \mathcal{I}$, μ_0 , ponto inicial $w_s^{(0)}$, uma sucessão não negativa $\{\tau_k\}$ com $\tau_k \rightarrow 0$
- 2 **Para** $k = 0, 1, \dots$
- 3 Encontrar um minimizante (aproximado) $w^{(k)}$ de $Q(w; \mu_k)$, iniciando em $w_s^{(k)}$ e terminar quando $\|\nabla Q(w; \mu_k)\| \leq \tau_k$
- 4 **Se** $w^{(k)}$ satisfaz o critério de paragem final
 Parar com a solução (aproximada) $w^{(k)}$
 fim se
- 5 Escolher novo parâmetro de penalidade $\mu_{k+1} > \mu_k$
- 6 Escolher novo ponto inicial $w_s^{(k+1)}$
- 7 Escolher nova tolerância $\tau_{k+1} < \tau_k$ (com $\tau_{k+1} > 0$)
- 8 **Fim para**
- 9 **Saída:** $w^* \leftarrow w^{(k)}$, $F^* \leftarrow F(w^{(k)})$ (solução ótima e valor ótimo)

Nota:

- devido à função $\max(0, -c_n)$, $Q(w; \mu_k)$ não é diferenciável nos pontos $w \in \{w \in \mathbb{R}^d : c_n(w) = 0, n \in \mathcal{I}\}$;
- $\nabla Q(w; \mu_k) = \nabla F(w) + \mu_k \sum_{n \in \mathcal{E}} c_n(w) \nabla c_n(w) - \mu_k \sum_{n \in \mathcal{I}} \max(0, -c_n(w)) \nabla c_n(w)$;
- $\nabla Q(w; \mu_k)$ não está definido nos pontos $w \in \{w \in \mathbb{R}^d : c_n(w) = 0, n \in \mathcal{I}\}$.

Observações sobre o Algoritmo

Suavidade dos termos de penalidade:

- **Restrições de igualdade:** os termos c_n^2 são suaves (pelo menos tão diferenciáveis quanto c_n).
⇒ quando apenas existem restrições de igualdade, podemos usar métodos de otimização sem restrições baseados em derivadas para encontrar a solução $w^{(k)}$ de $Q(w; \mu_k)$;
- **Restrições de desigualdade:** os termos $(\max(0, -c_n))^2$ podem ser menos suaves do que c_n .

Exemplo: se uma restrição é $w_1 \geq 0$, então o termo de penalidade é $(\max(0, -w_1))^2$, cuja segunda derivada é descontínua em $w_1 = 0$. Logo, Q não é, em geral, duas vezes continuamente diferenciável.

- A minimização de $Q(w; \mu_k)$ torna-se mais difícil de realizar à medida que μ_k aumenta.

Escolha do ponto inicial $w_s^{(k)}$ para minimizar $Q(w; \mu_k)$:

- usar um dos minimizantes anteriores de $Q(w; \mu)$: $w^{(k-1)}, w^{(k-2)}, \dots$ (“warm start”:
 $w_s^{(k)} = w^{(k-1)}$);
- ...

Escolha da sucessão $\{\mu_k\}$: pode ser adaptativa. Por exemplo, dependendo do custo computacional da minimização de $Q(w; \mu_k)$:

- elevado: fazer um aumento modesto, por exemplo, $\mu_{k+1} = 1.5 \mu_k$;
- reduzido: fazer um aumento maior, por exemplo, $\mu_{k+1} = 10 \mu_k$.

Escolha da sucessão $\{\tau_k\}$: $\tau_k \rightarrow 0$,

ou seja, a minimização é realizada progressivamente com maior precisão.

Critério de paragem $\|\nabla_w Q(w; \mu_k)\| \leq \tau_k$:

⇒ não há garantias de que este critério seja satisfeito, pois os iterados podem afastar-se da região admissível quando μ_k não é suficientemente grande;

⇒ uma implementação prática deve incluir salvaguardas que aumentem o parâmetro de penalidade (e, possivelmente, restaurem o ponto inicial) quando a violação das restrições não decresce suficientemente rápido ou quando os iterados parecem ser divergentes.

Nota: para escolhas adequadas de μ_k e do ponto inicial $w_s^{(k)}$, a minimização de $Q(w; \mu_k)$ é, em geral, efetuada em poucas iterações.

Exercício1: Considere o problema



$$\underset{w \in \mathbb{R}^2}{\text{minimizar}} \quad F(w) = w_1 + w_2 \quad \text{sujeito a} \quad w_1^2 + w_2^2 - 2 = 0$$

cujas solução é $(-1, -1)^T$. Minimize a função de penalidade quadrática $Q(w; \mu)$ do problema, com $\mu = 1$ e $\mu = 10$, usando um algoritmo de otimização sem restrições. Faça os gráficos dos contornos de Q .

Nota: usar a função *fminunc* do MATLAB para calcular os minimizantes/maximizantes de Q



Solução: $Q(w; \mu) = w_1 + w_2 + \frac{\mu}{2}(w_1^2 + w_2^2 - 2)^2$

- Para $\mu = 1$, a função $Q(w; 1)$ tem um minimizante no ponto $(-1.1072, -1.1072)^T$ e um maximizante no ponto $(0.2696, 0.2696)^T$.



- Para $\mu = 10$, a função $Q(w; 10)$ tem um minimizante no ponto $(-1.0123, -1.0123)^T$, o qual está mais perto da solução $(-1, -1)^T$.

Q tem um maximizante no ponto $(0.025, 0.025)^T$, e Q vai rapidamente para ∞ para pontos fora da circunferência $w_1^2 + w_2^2 = 2$.



Nota: para $\mu = 10$, os pontos que não satisfazem a restrição sofrem uma maior penalização - o “vale” de valores baixos de Q é evidente na figura.

A situação nem sempre é tão *favorável* como a reportada no Exercício1. Para um dado valor do parâmetro de penalidade μ , a função de penalidade pode ser ilimitada inferiormente ainda que o problema com restrições original tenha uma única solução. Esta deficiência é, infelizmente, comum a todas as funções de penalidade aqui apresentadas.



Exercício2: Considere o problema

$$\underset{w \in \mathbb{R}^2}{\text{minimizar}} \quad F(w) = -5w_1^2 + w_2^2 \quad \text{sujeito a } w_1 = 1$$



cujas solução é $(1, 0)^T$. Minimize a função de penalidade quadrática $Q(w; \mu)$ do problema, com $\mu = 1$ e $\mu = 100$, usando um algoritmo de otimização sem restrições. Faça os gráficos dos contornos de Q .

Solução: a função $Q(w; \mu) = -5w_1^2 + w_2^2 + \frac{\mu}{2}(w_1 - 1)^2$ é ilimitada inferiormente para $\mu < 10$.

- Para $\mu = 1 < 10$, a função $Q(w; 1)$ é ilimitada inferiormente e por isso o `fminunc` do MATLAB é incapaz de minimizar $Q(w; 1)$. O algoritmo parou ao fim de 1ª iteração com `exitflag=-3 'objective function at current iteration went below ObjectiveLimit'`.



- Para $\mu = 100$ e usando o `fminunc`, o algoritmo parou ao fim de 2ª iteração com `exitflag=1` 'magnitude of gradient is smaller than the *OptimalityTolerance* tolerance'. $Q(w; 100)$ tem um minimizante no ponto $(1.1111, 0)^T$, o qual está próximo da solução $(1, 0)^T$.



Exercício3: Considere novamente o problema

$$\underset{w \in \mathbb{R}^2}{\text{minimizar}} \quad F(w) = w_1 + w_2 \quad \text{sujeito a} \quad w_1^2 + w_2^2 - 2 = 0$$

- a) Minimize a função de penalidade quadrática Q do problema, para $\mu_k = 1, 10, 100, 1000$ usando um algoritmo de otimização sem restrições.
- b) Implemente o Método de Penalidade Quadrática (Algoritmo 8.1) para resolver o problema, com $w_s^{(0)} = (0, 0)^T$ e $\mu_0 = 1$. Faça $\mu_{k+1} = 10\mu_k$, $\tau_k = 1/\mu_k$ e escolha para ponto inicial $w_s^{(k+1)}$ a solução de $Q(w; \mu_k)$. Para critério de paragem final use as condições:

$$\|\nabla Q(w^{(k)}; \mu_k)\|_\infty \leq \varepsilon_1 \quad \text{e} \quad \|c_{\mathcal{E}}(w^{(k)})\|_\infty \leq \varepsilon_2 \quad (\text{medida da violação})$$

com $\varepsilon_1 = \varepsilon_2 = 10^{-6}$.

Indique a solução (aproximada) de cada função de penalidade $Q(w; \mu_k)$.

- c) Compare a solução ótima obtida em b) com a solução obtida utilizando a função `fmincon` do MATLAB.

São descritas, em dois teoremas, algumas propriedades do **Método de Penalidade Quadrática**. Considera-se apenas o problema com restrições de igualdade:

$$\begin{array}{ll} \underset{w \in \mathbb{R}^d}{\text{minimizar}} & F(w) \\ \text{sujeito a} & c_n(w) = 0, \quad n \in \mathcal{E} \end{array} \quad (\text{P1})$$

Para este problema, a função de penalidade quadrática é definida por:

$$Q(w; \mu) = F(w) + \frac{\mu}{2} \sum_{n \in \mathcal{E}} (c_n(w))^2 \quad (\text{PQ1})$$

Assume-se ainda que $\mu_k \uparrow \infty$, isto é, a sucessão $\{\mu_k\}$ é estritamente crescente ($\mu_{k+1} > \mu_k$ para todo k) e satisfaz

$$\lim_{k \rightarrow +\infty} \mu_k = +\infty.$$

Para o primeiro resultado, assume-se que a função de penalidade $Q(w; \mu_k)$ admite um minimizante global para cada valor de μ_k .

Teorema 1 (Teorema 17.1 em 1.)

Suponha que cada $w^{(k)}$ é o minimizante global exato de $Q(w; \mu_k)$ definida em (PQ1) no Algoritmo 7.1 acima, e que $\mu_k \uparrow \infty$. Então, todo ponto limite w^ da sucessão $\{w^{(k)}\}$ é uma solução global do problema (P1).*

Nota: este resultado é, em geral, impraticável na prática, pois exige a minimização global de cada subproblema $Q(w; \mu_k)$ (ou que o problema seja convexo).

Demonstração: Seja $\bar{w}$ a solução global de (P1), isto é,

$$F(\bar{w}) \leq F(w) \text{ para todo } w \text{ com } c_n(w) = 0, n \in \mathcal{E}$$

Como $w^{(k)}$ minimiza $Q(w; \mu_k)$ para cada k , tem-se que $Q(w^{(k)}; \mu_k) \leq Q(\bar{w}; \mu_k)$, donde segue a desigualdade

$$F(w^{(k)}) + \frac{\mu_k}{2} \sum_{n \in \mathcal{E}} (c_n(w^{(k)}))^2 \leq F(\bar{w}) + \frac{\mu_k}{2} \sum_{n \in \mathcal{E}} (c_n(\bar{w}))^2 = F(\bar{w}) \quad (1)$$

Reorganizando esta expressão, obtém-se

$$\sum_{n \in \mathcal{E}} (c_n(w^{(k)}))^2 \leq \frac{2}{\mu_k} [F(\bar{w}) - F(w^{(k)})]. \quad (2)$$

Suponha que w^* é o limite da sucessão $\{w^{(k)}\}$, então existe uma subsucessão infinita $\mathcal{K}$ tal com

$$\lim_{k \in \mathcal{K}} w^{(k)} = w^*.$$

Fazendo o limite $k \rightarrow \infty$ para $k \in \mathcal{K}$, em ambos os lados de (2), obtém-se

$$\sum_{n \in \mathcal{E}} (c_n(w^*))^2 = \lim_{k \in \mathcal{K}} \sum_{n \in \mathcal{E}} (c_n(w^{(k)}))^2 \leq \lim_{k \in \mathcal{K}} \frac{2}{\mu_k} [F(\bar{w}) - F(w^{(k)})] = 0$$

onde a última igualdade vem de $\mu_k \uparrow \infty$. Portanto, tem-se que $c_n(w^*) = 0$ para todo $n \in \mathcal{E}$, pelo que w^* é ponto admissível. Além disso, fazendo o limite $k \rightarrow \infty$ para $k \in \mathcal{K}$ em (1), tem-se pela não negatividade de μ_k e de cada $(c_n(w^{(k)}))^2$ que

$$F(w^*) \leq F(w^*) + \lim_{k \in \mathcal{K}} \frac{\mu_k}{2} \sum_{n \in \mathcal{E}} (c_n(w^{(k)}))^2 \leq F(\bar{w}).$$

Como w^* é um ponto admissível cujo valor da função objetivo não é maior do que na solução global $\bar{w}$, conclui-se que w^* , também, é uma solução global do problema (P1). $\square$

- O segundo resultado diz respeito às propriedades de convergência da sucessão $\{w^{(k)}\}$ quando as minimizações de $Q(w; \mu_k)$ são efetuadas de forma não exata, mas cada vez com mais precisão.
- Em contraste com o Teorema 1, este resultado mostra que a sucessão pode convergir:
 - ▷ para pontos não admissíveis, ou
 - ▷ para um ponto KKT - isto é, um ponto que satisfaz as condições necessárias de primeira ordem. Também mostra que as quantidades $\mu_k c_n(w^{(k)})$ podem ser utilizadas como estimativas dos multiplicadores de Lagrange λ_n^* .

Para estabelecer os resultados do Teorema 2, assume-se que o critério de paragem $\|\nabla_w Q(w; \mu_k)\| \leq \tau_k$ é satisfeito para todo k .

Teorema 2 (Teorema 17.2 em 1.)

Suponha que as tolerâncias e os parâmetros de penalidade no Algoritmo 7.1 satisfazem $\tau_k \rightarrow 0$ e $\mu_k \uparrow \infty$. Se um ponto limite w^* da sucessão é não-admissível, então w^* é um ponto estacionário da função $\|c_{\mathcal{E}}(w)\|^2$. Por outro lado, se um ponto limite w^* da sucessão é um ponto admissível e os gradientes $\nabla c_n(w^*)$ são linearmente independentes, então w^* é um ponto KKT do problema com restrições (P1), e, para qualquer subsucessão infinita tal que $\lim_{k \in \mathcal{K}} w^{(k)} = w^*$, tem-se que

$$\lim_{k \in \mathcal{K}} -\mu_k c_n(w^{(k)}) = \lambda_n^*, \quad \text{para todo } n \in \mathcal{E} \quad (3)$$

onde λ^* é o vector dos multiplicadores de Lagrange que satisfazem as condições KKT para o problema com restrições de igualdade (P1).

Demonstração Derivando $Q(w; \mu_k)$ em (PQ1), obtém-se:

$$\nabla_w Q(w^{(k)}; \mu_k) = \nabla F(w^{(k)}) + \sum_{n \in \mathcal{E}} \mu_k c_n(w^{(k)}) \nabla c_n(w^{(k)}). \quad (4)$$

Pelo critério de paragem do Algoritmo1, tem-se que

$$\|\nabla F(w^{(k)}) + \mu_k \sum_{n \in \mathcal{E}} c_n(w^{(k)}) \nabla c_n(w^{(k)})\| \leq \tau_k. \quad (5)$$

Usando a desigualdade $\|a\| - \|b\| \leq \|a + b\|$, obtém-se

$$\begin{aligned} \mu_k \left\| \sum_{n \in \mathcal{E}} c_n(w^{(k)}) \nabla c_n(w^{(k)}) \right\| - \|\nabla F(w^{(k)})\| &\leq \tau_k \Leftrightarrow \\ \left\| \sum_{n \in \mathcal{E}} c_n(w^{(k)}) \nabla c_n(w^{(k)}) \right\| &\leq \frac{1}{\mu_k} [\tau_k + \|\nabla F(w^{(k)})\|]. \end{aligned} \quad (6)$$

Seja w^* um ponto limite da sucessão $\{w^{(k)}\}$. Então existe uma subsucessão $\mathcal{K}$ tal que $\lim_{k \in \mathcal{K}} w^{(k)} = w^*$.

Fazendo o limite com $k \rightarrow \infty$ para $k \in \mathcal{K}$, em ambos os lados de (6), o termo dentro do parêntesis do lado direito aproxima-se de $\|\nabla F(w^*)\|$. Como $\mu_k \uparrow \infty$, o lado direito aproxima-se de zero. Considerando o limite no lado esquerdo, obtém-se:

$$\sum_{n \in \mathcal{E}} c_n(w^*) \nabla c_n(w^*) = 0. \quad (7)$$

Podemos ter $c_n(w^*) \neq 0$ se os gradientes das restrições $\nabla c_n(w^*)$ são linearmente dependentes em w^* . Neste caso (7) implica que w^* é um ponto estacionário da função $\|c_{\mathcal{E}}(w)\|^2$.

Se, por outro lado, os gradientes das restrições $\nabla c_n(w^*)$ são linearmente independentes, tem-se de (7) que $c_n(w^*) = 0$ para todo $n \in \mathcal{E}$, portanto w^* é um ponto admissível. Logo, a 2ª condição das condições KKT (condição de admissibilidade) é satisfeita. É necessário verificar também a 1ª condição KKT e mostrar que o limite (3) é válido.

Denotando por $A(w)$ a matriz dos gradientes das restrições

$$A(w)^T = [\nabla c_n]_{n \in \mathcal{E}},$$

e denotando por $\lambda^{(k)}$ o vetor $-\mu_k c(w^{(k)})$, tem-se por (4) e (5) que

$$A(w^{(k)})^T \lambda^{(k)} = \nabla F(w^{(k)}) - \nabla_w Q(w^{(k)}; \mu_k), \quad \|\nabla_w Q(w^{(k)}; \mu_k)\| \leq \tau_k. \quad (8)$$

Para todo $k \in \mathcal{K}$ suficientemente grande, a matriz $A(w^{(k)})$ tem característica completa por linhas, assim $A(w^{(k)})A(w^{(k)})^T$ é não singular. Multiplicando (8) por $A(w^{(k)})$ e reorganizando obtém-se:

$$\lambda^{(k)} = \left[A(w^{(k)})A(w^{(k)})^T \right]^{-1} A(w^{(k)}) \left[\nabla F(w^{(k)}) - \nabla_w Q(w^{(k)}; \mu_k) \right]$$

Portanto, fazendo o limite $k \rightarrow \infty$ para $k \in \mathcal{K}$, obtém-se

$$\lim_{k \in \mathcal{K}} \lambda^{(k)} = \lambda^* = \left[A(w^*)A(w^*)^T \right]^{-1} A(w^*) \nabla F(w^*).$$

Fazendo o limite em (5), conclui-se que

$$\nabla F(w^*) - A(w^*)^T \lambda^* = 0,$$

assim λ^* satisfaz a 1ª condição KKT para o problema (P1). Portanto, w^* é um ponto KKT para o problema (P1), com único vetor de multiplicadores de Lagrange λ^* . $\square$

Funções de Penalidade Exatas Não Suaves:

- Algumas funções de penalidade $\phi(w; \mu)$ são exatas, isto é, para certas escolhas do parâmetro de penalidade ($\exists \mu^* > 0$ tal que $\forall \mu > \mu^*$), uma única minimização de $\phi(w; \mu)$ pode fornecer a solução exata do problema com restrições (P_{CR}).
- Esta propriedade é desejável, pois torna o desempenho dos métodos de penalidade menos dependente da estratégia de atualização do parâmetro de penalidade.
- **Nota:** A função de penalidade quadrática $Q(w; \mu)$ não é exata, uma vez que o seu minimizante, em geral, não coincide com a solução do problema (P_{CR}) para qualquer valor positivo de μ . Por isso, é necessário considerar $\mu_k \uparrow \infty$.

Uma **função de penalidade exata não suave**, muito usada para o problema de otimização não linear com restrições (P_{CR}), é a **função de penalidade ℓ_1** , definida por:

$$\phi_1(w; \mu) = F(w) + \mu \sum_{n \in \mathcal{E}} |c_n(w)| + \mu \sum_{n \in \mathcal{I}} \max(0, -c_n(w))$$

- O seu nome deriva do facto de o termo de penalidade corresponder a μ vezes a norma ℓ_1 da violação das restrições.

(Nota: a norma $\|\cdot\|_1$ é também conhecida como norma ℓ_1).

O nome deriva do facto de o termo de penalidade corresponder a μ vezes uma norma ℓ_1 da violação das restrições.

- Note-se que $\phi_1(w; \mu)$ não é diferenciável em alguns pontos w , devido à presença das funções $|\cdot|$ e $\max(0, -c_n(w))$.

O resultado seguinte estabelece a exatidão da função de penalidade ℓ_1 .

Teorema 3 (Teorema 17.3 em 1.)

Suponha que w^* é uma *solução local estrita do problema com restrições* (P_{CR}) para o qual as condições necessárias de 1ª ordem são satisfeitas (condições KKT), com multiplicadores de Lagrange λ_n^* , $n \in \mathcal{E} \cup \mathcal{I}$. Então w^* é um *minimizante local de* $\phi_1(w; \mu)$ para todo $\mu > \mu^*$, onde

$$\mu^* = \|\lambda^*\|_\infty = \max_{n \in \mathcal{E} \cup \mathcal{I}} |\lambda_n^*| \quad (9)$$

Se, adicionalmente, as condições suficientes de 2ª ordem são satisfeitas e $\mu > \mu^*$, então w^* é um *minimizante local estrito de* $\phi_1(w; \mu)$.

Em termos gerais, numa solução w^* do problema com restrições (P_{CR}), qualquer deslocamento para a região não admissível é penalizado de forma suficientemente severa, de modo a aumentar o valor da função de penalidade para um valor superior a $\phi_1(w^*; \mu) = F(w^*)$, forçando assim o minimizante de $\phi_1(w; \mu)$ a situar-se em w^* .

Exemplo: Considere o seguinte problema numa variável:

$$\underset{w \in \mathbb{R}}{\text{minimizar}} \quad F(w) = w \text{ sujeito a } w \geq 1$$

cuja solução é $w^* = 1$. Indicar para que valores de μ , a solução $w^* = 1$ é um minimizante da função de penalidade ℓ_1 .

Resolução: A função de penalidade ℓ_1 é dada por:

$$\phi_1(w; \mu) = w + \mu \max(0, -(w - 1)) = \begin{cases} (1 - \mu)w + \mu & \text{se } w < 1 \\ w & \text{se } w \geq 1 \end{cases}$$

- se $1 - \mu < 0 \Leftrightarrow \mu > 1$, então ϕ_1 é monótona decrescente para $w < 1$; e crescente para $w \geq 1$, pelo que ϕ_1 tem um minimizante em $w^* = 1$.
- se $1 - \mu > 0 \Leftrightarrow \mu < 1$, então ϕ_1 é monótona crescente para todo $w \in \mathbb{R}$.





Figura 3: Função de penalidade ϕ_1 com $\mu > 1$ (esq.) e $\mu < 1$ (dir.)

Como os métodos de penalidade funcionam minimizando diretamente a função de penalidade, é necessário caracterizar os pontos estacionários de ϕ_1 . Embora ϕ_1 não seja diferenciável, possui derivada direcional $D(\phi_1(w; \mu); s)$ ao longo de qualquer direção s .

Recordar:

A derivada direcional de uma função $F : \mathbb{R}^d \rightarrow \mathbb{R}$ na direção de s é dada por:

$$D(F(w); s) = \lim_{\varepsilon \rightarrow 0} \frac{F(w + \varepsilon s) - F(w)}{\varepsilon}.$$

Notar que, a $D(F(w); s)$ pode estar bem definida mesmo quando F não é continuamente diferenciável. Quando F é de facto continuamente diferenciável numa vizinha de w , tem-se: $D(F(w); s) = \nabla F(w)^T s$.

Definição

Um ponto $\hat{w} \in \mathbb{R}^d$ é um ponto estacionário para a função de penalidade $\phi_1(w; \mu)$ se

$$\mathcal{D}(\phi_1(\hat{w}; \mu); s) \geq 0, \text{ para todo } s \in \mathbb{R}^d$$

Do mesmo modo, $\hat{w}$ é um ponto estacionário da **medida de não admissibilidade**

$$h(w) = \sum_{n \in \mathcal{E}} |c_n(w)| + \sum_{n \in \mathcal{I}} [\max(0, -c_n(w))] \quad (\text{medida de violação})$$

se $D(h(\hat{w}); s) \geq 0$ para todo $s \in \mathbb{R}^d$. Se um ponto é não admissível para o problema (P_{CR}) mas estacionário em relação à medida de não admissibilidade h , dizemos que é um ponto estacionário não admissível.

Exemplo: Considere novamente o problema de uma variável:

$$\underset{w \in \mathbb{R}}{\text{minimizar}} \quad F(w) = w \quad \text{sujeito a } w \geq 1$$

cujas solução é $w^* = 1$. Calcular a derivada direcional da função $\phi_1(w; \mu)$ no ponto $w^* = 1$.

Resolução: Sabemos que

$$\phi_1(w; \mu) = w + \mu \max(0, -(w - 1)) = \begin{cases} (1 - \mu)w + \mu & \text{se } w < 1 \\ w & \text{se } w \geq 1 \end{cases}$$

A derivada direcional de $\phi_1(w; \mu)$ no ponto $w^* = 1$ é dada por:

$$\begin{aligned} D(\phi_1(1; \mu); s) &= \lim_{\varepsilon \rightarrow 0} \frac{\phi_1(1 + \varepsilon s; \mu) - \phi_1(1; \mu)}{\varepsilon} = \\ &= \lim_{\varepsilon \rightarrow 0} \begin{cases} \frac{1 + \varepsilon s - 1}{\varepsilon} & \text{se } s \geq 0 \\ \frac{(1 - \mu)(1 + \varepsilon s) + \mu - 1}{\varepsilon} & \text{se } s < 0 \end{cases} \\ &= \lim_{\varepsilon \rightarrow 0} \begin{cases} s & \text{se } s \geq 0 \\ \frac{(1 - \mu)\varepsilon s}{\varepsilon} & \text{se } s < 0 \end{cases} = \begin{cases} s & \text{se } s \geq 0 \\ (1 - \mu)s & \text{se } s < 0 \end{cases} \end{aligned}$$

donde se conclui que quando $1 - \mu < 0 \Leftrightarrow \mu > 1$, $D(\phi_1(w^*; \mu); s) \geq 0$ para todo $s \in \mathbb{R}$. Portanto, $w^* = 1$ é um ponto estacionário da função $\phi_1(w; \mu)$ com $\mu > 1$.

O resultado seguinte complementa o Teorema 3, mostrando que os pontos estacionários de $\phi_1(w; \mu)$ correspondem a pontos KKT do problema com restrições (P_{CR}) sob certas hipóteses.

Teorema 4 (Teorema 17.4 em 1.)

Suponha que $\hat{w}$ é um ponto estacionário da função de penalidade $\phi_1(w; \mu)$ para todo μ maior que um certo valor limiar $\hat{\mu} > 0$. Então, se $\hat{w}$ for admissível para o problema com restrições (P_{CR}), ele satisfaz as condições de KKT para (P_{CR}). Se $\hat{w}$ não for admissível para (P_{CR}), então é um ponto estacionário não admissível.

Exercício: Considere novamente o problema

$$\underset{w \in \mathbb{R}^2}{\text{minimizar}} \quad F(w) = w_1 + w_2 \text{ sujeito a } w_1^2 + w_2^2 - 2 = 0$$

cuja solução é $w^* = (-1, -1)^T$. Indicar para que valores de μ , a solução w^* é um minimizante da função de penalidade ℓ_1 .

Solução: A função de penalidade ℓ_1 do problema é

$$\phi_1(w; \mu) = w_1 + w_2 + \mu |w_1^2 + w_2^2 - 2|.$$

Pelo Teorema 3 temos que para todo $\mu > |\lambda^*| = 0.5$, o minimizante de $\phi_1(w; \mu)$ coincide com w^* . A Figura 4 mostra os contornos de $\phi_1(w; \mu)$ para $\mu = 2$. Os cantos pontiagudos nos contornos indicam a não de suavidade da função $\phi_1(w; 2)$ ao longo da fronteira do círculo definido por $w_1^2 + w_2^2 = 2$.





Figura 4: Função de penalidade ℓ_1 para $\mu = 2$.

O **Método de Penalidade ℓ_1** é definido pelo seguinte algoritmo.

Algoritmo 8.2: Método de Penalidade ℓ_1

- ❶ **Entrada:** F e c_n para $n \in \mathcal{E} \cup \mathcal{I}$, μ_0 , ponto inicial $w_s^{(0)}$, tolerância τ
 - ❷ **Para** $k = 0, 1, \dots$
 - ❸ Encontrar um minimizante (aproximado) $w^{(k)}$ de $\phi_1(w; \mu_k)$, iniciando em $w_s^{(k)}$
 - ❹ **Se** $h(w^{(k)}) \leq \tau$
 Parar com a solução aproximada $w^{(k)}$
 fim se
 - ❺ Escolher novo parâmetro de penalidade $\mu_{k+1} > \mu_k$
 - ❻ Escolher novo ponto inicial $w_s^{(k+1)}$
 - ❼ **Fim para**
 - ❽ **Saída:** $w^* \leftarrow w^{(k)}$, $F^* \leftarrow F(w^{(k)})$ (solução ótima e valor ótimo)
-

Observações sobre o Algoritmo

Minimizar $\phi_1(w; \mu)$:

Esta função não é suave, pois o seu gradiente não está definido nos pontos w tais que $c_n(w) = 0$ para algum $n \in \mathcal{E} \cup \mathcal{I}$.

⇒ usar métodos de otimização sem derivadas; ou

⇒ construir um modelo suave de $\phi_1(w; \mu)$ e minimizá-lo (ver Secção 17.2 em 1.).

Estratégia para atualizar μ_k :

Uma estratégia simples consiste em aumentar sucessivamente o parâmetro:

$$\mu_{k+1} = a \mu_k, \quad (\text{por exemplo } a = 5 \text{ ou } a = 10).$$

Esta estratégia é prática, mas pode ser ineficiente:

- μ_0 demasiado pequeno ⇒ podem ser necessários muitos ciclos do Algoritmo 8.2 para obter uma solução aproximada;
- μ_k demasiado grande ⇒ a função de penalidade torna-se difícil de minimizar, exigindo possivelmente um grande número de iterações.

- Outra estratégia seria escolher μ_k , em cada iteração, modo a satisfazer

$$\mu_k > \|\lambda_k\|_\infty,$$

onde λ_k é uma estimativa dos multiplicadores de Lagrange em $w^{(k)}$. Esta estratégia baseia-se no Teorema 3, que sugere que, numa vizinhança de uma solução w^* , uma boa escolha é tomar μ_k ligeiramente maior do que $\|\lambda^*\|_\infty$.

No entanto, esta estratégia nem sempre é bem-sucedida, uma vez que as estimativas dos multiplicadores podem ser imprecisas e pouco fiáveis quando os iterados estão longe da solução.

Escolha do ponto inicial $w_s^{(k+1)}$ para minimizar $\phi_1(x; \mu_{k+1})$:

- Se o parâmetro μ_k no ciclo atual for adequado, no sentido em que houve progresso em direção à admissibilidade, pode-se tomar $w_s^{(k+1)} = w^{(k)}$, o minimizante obtido neste ciclo. Caso contrário, pode ser necessário restaurar o ponto inicial de um ciclo anterior.

Classe Geral de Métodos de Penalidade Exata Não Suaves:

As **funções de penalidade exatas não suaves** podem ser definidas em termos de normas diferentes da norma ℓ_1 :

$$\phi(w, \mu) = F(w) + \mu \|c_{\mathcal{E}}\| + \mu \|\max(0, -c_{\mathcal{I}})\| \quad (10)$$

onde

- $\|\cdot\|$ é uma **norma vetorial qualquer**;
- todas as funções de restrição de igualdade e desigualdade foram agrupadas nas funções vetoriais $c_{\mathcal{E}} : \mathbb{R}^d \rightarrow \mathbb{R}^{|\mathcal{E}|}$ e $c_{\mathcal{I}} : \mathbb{R}^d \rightarrow \mathbb{R}^{|\mathcal{I}|}$.
- O Algoritmo 8.2 aplica-se a qualquer uma destas funções $\phi(w; \mu)$ com a medida de não admissibilidade h definida por

$$h(w) = \|c_{\mathcal{E}}\| + \|\max(0, -c_{\mathcal{I}})\|.$$

- As normas mais usadas na prática são as normas ℓ_1 , ℓ_∞ e ℓ_2 (não ao quadrado).
- As propriedades teóricas descritas para a função de penalidade ℓ_1 estendem-se para a classe geral (10). No Teorema 3, substitui-se a igualdade (9) por

$$\mu^* = \|\lambda^*\|_D$$

onde $\|\cdot\|_D$ é a norma dual de $\|\cdot\|$.

- O Teorema 4 aplica-se sem modificação.

- ① Jorge Nocedal and Stephen Wright. **Numerical Optimization**, Second Edition, Springer 2006.